FUNDOSCOPY STUDY · AI 학습자료

Mamba & Vision Mamba 쉬운 스텝바이스텝

CNN · ViT · 어텐션을 아는 분을 위한 안내서

비유로 이해 → 아주 작은 숫자로 확인 → 연습문제로 마무리

이 책을 읽는 법

이 책은 **"이미 CNN과 ViT(어텐션)를 아는 사람"** 을 기준으로 씁니다. 여러분이 아는 것에서 출발해 조금씩만 나아갑니다.

여러분이 이미 아는 것	이 책이 붙이는 것
CNN: 작은 커널(필터)을 미끄러뜨리며 합성곱	그 "필터"가 여기서도 똑같이 나옵니다(Step 5)
ViT/어텐션: 모든 토큰이 모든 토큰을 봄, $O(L^2)$	그걸 더 싸게 하는 방법(Step 1, 10)
softmax, 가중평균, 벡터·행렬 곱	그대로 씁니다(새로 외울 것 거의 없음)
고3 수학: 지수 e^x, 합 기호 $\sum$	계산은 전부 이 수준입니다

약속: 수식이 나오면 **기호마다 뜻을 우리말로** 붙입니다. 어려운 행렬 계산은 쓰지 않고, 처음엔 숫자 하나(스칼라)로만 봅니다.

Step 1. 어텐션은 왜 비쌀까 (출발점)

ViT에서 이미지를 16×16 패치로 자르면 토큰이 **196개**쯤 됩니다. 어텐션은 **모든 토큰이 모든 토큰을** 봅니다.



그림 1. 세 가지 시야 — CNN은 국소, 어텐션은 전부, SSM은 체인으로 이어받기.

문제는 "전부 봄"이 **비용이 제곱으로 커진다**는 것. Mamba의 아이디어는 한마디로:

> **"전부 보지 말고, 요약 메모리를 이어받자."** 어텐션의 전역 시야를 유지하면서 비용을 $O(L^2) \rightarrow O(L)$ 로 줄입니다.

연습 1 CNN / 어텐션 / SSM 각각이 "무엇을 보고 계산하는가"를 한 줄씩 쓰시오.

Step 2. SSM = 요약 메모리 (릴레이 비유)

비유 계주 선수들이 바통을 이어받듯, 토큰을 하나씩 읽으며 **"지금까지의 요약"**을 다음으로 넘깁니다. 그 바통이 **상태 h** 입니다.

토큰을 하나 처리할 때마다 상태를 이렇게 갱신합니다(아주 단순화한 스칼라 버전):

$$h_t = \underbrace{\bar{A}}_{\text{기억이 남는 비율}} h_{t-1} + \underbrace{\bar{B}}_{\text{새 입력 담는 양}} x_t, \qquad y_t = C\,h_t$$

기호	읽는 법	느낌
x_t	t번째 입력 토큰	새로 읽은 패치의 요약값
h_{t-1}	직전까지의 상태	넘겨받은 바통(과거 요약)
$\bar{A}$	0과 1 사이 숫자	기억이 **얼마나 남는지** (0.5면 절반만)
$\bar{B}$	양수	새 입력을 **얼마나 담는지**
C	숫자	상태에서 **무엇을 읽어 출력**할지

핵심 감각: 오래된 정보는 매 스텝 $\bar{A}$ 씩 곱해져 점점 흐려집니다. 그래서 "요약"이지 "저장"이 아닙니다 — 이게 어텐션과의 결정적 차이(정보 병목)이자 장점(저비용).

연습 2 바통 비유로 상태 h 를 설명해 보세요. 또 $\bar{A} = 0$ 이면 무슨 일이 생길까요?

Step 3. “기억 손잡이” Δ

원래 SSM은 연속시간이라, 컴퓨터가 쓰려면 **스텝 크기 Δ** 로 이산화합니다. **Δ** 는 쉽게 말해 **기억 손잡이** 입니다.

$$\bar{A} = e^{-\Delta} \text{ (예시)}, \qquad \bar{B} \approx \Delta$$

> **비유** **Δ** 를 크게 → “지금 것만 또렷이 기억”(과거는 금방 잊음). **Δ** 를 작게 → “예전 것도 오래 기억”. 손잡이 하나로 **기억의 길이**를 조절.

Δ	**기억 남는 비율 $\bar{A} = e^{-\Delta}$**	**느낌**
0.1	0.90	오래 기억
1.0	0.37	금방 잊음(현재 중심)
3.0	0.05	직전 것만 기억

안정성: Mamba는 $\bar{A}$ 가 항상 0~1이 되게 설계합니다. 그래서 상태가 폭주하지 않고 학습이 안정적입니다(옛날 RNN의 고질병 해결).

> **연습 3** $\Delta = 1$ 일 때 $\bar{A} = e^{-1}$ 을 소수 4자리로 구하시오($e^{-1} \approx 0.3679$). 더 간단한 근사 $\bar{B} \approx \Delta$ 도 함께 쓰시오.

Step 4. 손으로 따라가기 (숫자 하나로)

$\bar{A} = 0.5,\ \bar{B} = 1$, 입력 $x = [1, 2, 3]$, 시작 상태 $h_0 = 0$.

t	x_t	계산	h_t
1	1	0.5·0 + 1·1	1.0
2	2	0.5·1 + 1·2	2.5
3	3	0.5·2.5 + 1·3	4.25

보시다시피 복잡한 게 없습니다 — 곱하고 더하기를 반복할 뿐입니다. 이게 SSM의 **순차(재귀) 계산**입니다.

> **연습 4** $\bar{A} = 0.5,\ \bar{B} = 1,\ x = [1, 2, 3]$ 의 h_1, h_2, h_3 를 직접 계산하시오(위 표와 같아야 함).

Step 5. 놀라운 사실 — 이건 사실 CNN 필터입니다

연결 여러분이 CNN에서 배운 **합성곱(커널을 미끄러뜨리기)**가 여기서 그대로 나옵니다. SSM을 "펼치면" 고정 커널과의 합성곱이 됩니다.

재귀를 풀어 쓰면 y 는 **커널 K 를 x 에 미끄러뜨린 결과**와 같습니다:

$$K_k = C\,\bar{A}^{\,k}\,\bar{B}, \qquad y_t = \sum_{k} K_k\, x_{t-k}$$

Step 4의 값으로: $\bar{A} = 0.5,\ \bar{B} = 1,\ C = 1 \rightarrow K = [1,\ 0.5,\ 0.25,\ \ldots]$ (0.5씩 줄어드는 필터!)

t	합성곱 계산	y_t
1	1·1	1.0
2	1·2 + 0.5·1	2.5
3	1·3 + 0.5·2 + 0.25·1	4.25

여기가 핵심 연결! Step 4의 재귀 결과와 Step 5의 합성곱 결과가 **정확히 같습니다**. 그래서 SSM은 CNN처럼 **병렬**로 계산할 수 있습니다(커널이 고정일 때).

연습 5 위 커널 $K = [1,\ 0.5,\ 0.25]$ 를 이용해 $x = [1, 2, 3]$ 의 y_3 를 계산하시오.

Step 6. 선택성 — 필터를 "입력이" 만든다

Step 5의 커널은 **고정**입니다. CNN 필터가 학습 후 고정되는 것과 같죠. 그런데 고정 필터는 "이건 중요, 저건 버려" 같은 **선택**을 못 합니다.

Mamba의 한 끗: $\bar{A}, \bar{B}, C$ 를 **매 토큰마다 입력에서 계산**합니다. 즉 **필터를 입력이 그때그때 만듭니다**.

$$(\Delta_t,\ B_t,\ C_t) = \text{작은 신경망}(x_t), \qquad \Delta_t = \mathrm{softplus}(\cdot)$$

	고정 필터 (CNN/기본 SSM)	입력이 만든 필터 (Mamba)
커널	학습 후 고정	토큰마다 새로 생성
병렬 합성곱	가능	**불가**(커널이 자꾸 바뀜)
능력	무엇이든 같은 방식	중요한 것만 골라 기억

대신 합성곱을 못 쓰니, 원래의 **순차 계산(재귀)** 을 다시 써야 합니다 → Step 7에서 이 순차 계산을 **병렬화**하는 방법을 봅니다.

연습 6 "입력이 필터를 만든다"는 것이 CNN의 고정 필터와 어떻게 다른지, 왜 장점인지 한 줄로 쓰시오.

Step 7. 순차 계산을 병렬로? (스캔 아이디어)

순차 계산은 앞이 끝나야 다음을 할 수 있어 느립니다. Mamba는 이 재귀를 **트리처럼 묶어서** 병렬화합니다. 어려운 수식 없이 아이디어만 보면:

아이디어: "h 를 갱신하는 규칙"을 두 개씩 짝지어 **합치기**. 합치는 순서를 바꿔도 결과가 같다는 성질(결합법칙) 덕분에, 한 번에 여러 쌍을 처리할 수 있습니다.

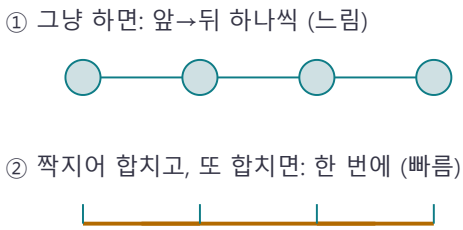


그림 2. 순차(①) 대신 짝지어 합치면(②) 병렬 계산이 가능해집니다.

결과는 순차와 **똑같고**, 속도는 병렬로. (PyTorch의 `tf.scan`/CUDA 커널이 이 원리)

연습 7 "순차 계산을 병렬로 바꾼다"는 아이디어를 한 문장으로 설명하시오.

Step 8. Mamba 블록 — 부품 세 개

지금까지 배운 걸 조립하면 Mamba 블록입니다. ViT 블록과 나란히 보면 이해가 쉽습니다.



부품	하는 일	여러분이 아는 것과 연결
Conv1d	이웃 토큰을 **살짝 섞기**	작은 CNN 커널 한 층
SSM	릴레이로 **전역 요약**(O(L))	Attention의 자리
gate	정보 **통과량 조절**	MLP + 게이팅

연습 8 Mamba 블록의 세 부품(Conv1d·SSM·gate)이 각각 하는 일을 한 줄씩 쓰시오.

Step 9. Vision Mamba — 이미지에 붙이기

ViT가 그랬듯, 이미지를 패치로 잘라 토큰으로 만듭니다. 224×224, 패치 16 → **196 토큰**.

그런데 이미지는 **정해진 순서가 없습니다.** 글은 왼→오가 자연스럽지만, 그림은 위→아래가 정답이 아닙니다. 그래서 **양쪽에서 두 번 읽습니다.**

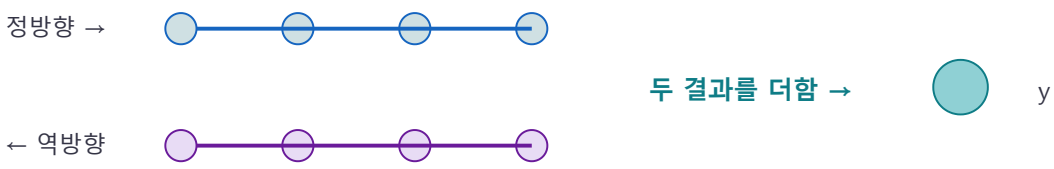


그림 3. 양방향 스캔 — 정방향 + 역방향을 합쳐 순서에 덜 민감하게.

어텐션은 순서가 없어도(순열 불변) 잘 동작하지만, SSM은 순서에 민감 → **양방향**으로 보완 + **Conv1d**로 이웃을 섞어 완화.

연습 9 224×224, 패치 16 이미지의 토큰 수를 구하고, 어텐션 행렬 원소 수(L^2)와 SSM 상태 크기($L \times N$, $N = 16$)를 비교하시오.

Step 10. 정리 & 안저(망막) 적용

	ViT (어텐션)	Vision Mamba
전역 상호작용	모든 토큰 쌍	양방향 릴레이 요약
비용	$O(L^2)$	$O(L)$
순서	상관없음	민감 → 양방향+Conv
선택	softmax 가중치	입력이 만든 필터(Δ,B,C)
기억	전부 저장	요약(작은 상태) → 병목

안저 사진에 왜 좋은가: 고해상도일수록 어텐션 비용이 급증합니다. Mamba는 선형이라 **GPU 없이도** 실험·추론이 가능합니다. Mamba 기본 하이퍼파라미터만 써도 CPU 모델을 만들 수 있습니다:

d_model	d_inner (×2)	dt_rank (÷16 올림)	d_state (N)
128	256	8	16
256	512	16	16

> **연습 10** $d_{model} = 192$ 일 때 d_{inner} 와 dt_rank 를 구하시오.

연습문제 (정답은 다음 장)

1. CNN / 어텐션 / SSM 이 각각 "무엇을 보고 계산하는가"?

2. 바통(상태 h) 비유로 SSM을 설명하고, $\bar{A} = 0$ 이면 어떤 모델 같아지는지.

3. $\Delta = 1$ 일 때 $\bar{A} = e^{-1}$ (소수 4자리)와 근사 $\bar{B} \approx \Delta$ 를 구하시오.

4. $\bar{A} = 0.5,\ \bar{B} = 1,\ x = [1, 2, 3]$ 의 h_1, h_2, h_3 를 계산하시오.

5. 커널 $K = [1, 0.5, 0.25]$ 로 $x = [1, 2, 3]$ 의 y_3 를 계산하시오.

6. "입력이 필터를 만든다"가 CNN 고정 필터와 어떻게 다른가?

7. 순차 계산을 병렬로 바꾸는 아이디어를 한 문장으로.

8. Mamba 블록의 세 부품 역할.

9. 224×224, 패치 16의 토큰 수, 어텐션 행렬 원소 수, SSM 상태 크기(N=16).

10. $d_{model} = 192$ 에서 d_{inner}, dt_rank.

정답과 해설

1 CNN은 **국소**(이웃 몇 개), 어텐션은 **전부**(모든 토큰 쌍), SSM은 **체인**(앞에서 뒤로 요약을 이어받음).

2 토큰을 읽을 때마다 "지금까지의 요약(바통)"을 갱신해 다음으로 넘긴다. $\bar{A} = 0$ 이면 과거를 전부 버리고 직전 입력만 남아 **메모리 없는 신경망(MLP)** 처럼 된다.

3 $\bar{A} = e^{-1} = 0.3679$, $\bar{B} \approx \Delta = 1$. (참고로 정확한 값은 0.6321)

4 $h_1 = 0.5 \cdot 0 + 1 = 1.0$, $h_2 = 0.5 \cdot 1 + 2 = 2.5$, $h_3 = 0.5 \cdot 2.5 + 3 = 4.25$.

5 $y_3 = K_0 x_3 + K_1 x_2 + K_2 x_1 = 1 \cdot 3 + 0.5 \cdot 2 + 0.25 \cdot 1 = 4.25$. (연습 4와 같은 값!)

6 CNN 필터는 학습 후 **고정**이라 모든 입력에 똑같이 적용된다. Mamba는 토큰마다 Δ, B, C 를 새로 만들어 **중요한 것만 골라 기억**할 수 있다.

7 재귀 갱신 규칙을 두 개씩 **짝지어 합치는** 방식을 쓰면(결합법칙), 한 번에 여러 쌍을 처리해 병렬로 계산할 수 있다.

8 **Conv1d**=이웃 토큰 섞기(지역성), **SSM**=전역 요약(어텐션 자리), **gate**=정보 통과량 조절(MLP 자리).

9 토큰 $= (224/16)^2 = 196$. 어텐션 행렬 $= 196^2 = \mathbf{38{,}416}$. SSM 상태 $= 196 \times 16 = \mathbf{3{,}136}$.

10 $d_{inner} = 2 \cdot 192 = \mathbf{384}$, $dt_rank = \lceil 192/16 \rceil = \mathbf{12}$.

더 공부하려면

- 인터랙티브 애니메이션: `docs/vision-mamba.html` (슬라이더로 Δ 조절 등)

- 슬라이드 덱: `slides/vision-mamba.pdf` (18장)
- 구현 계획: `app/PLAN-keras-tensorflow.md`

계산값은 모두 스크립트로 검증했습니다. 의료진 학습용 자료입니다.